

# Identifikacija parametara modela

[http://www.fer.hr/predmet/aru\\_a](http://www.fer.hr/predmet/aru_a)

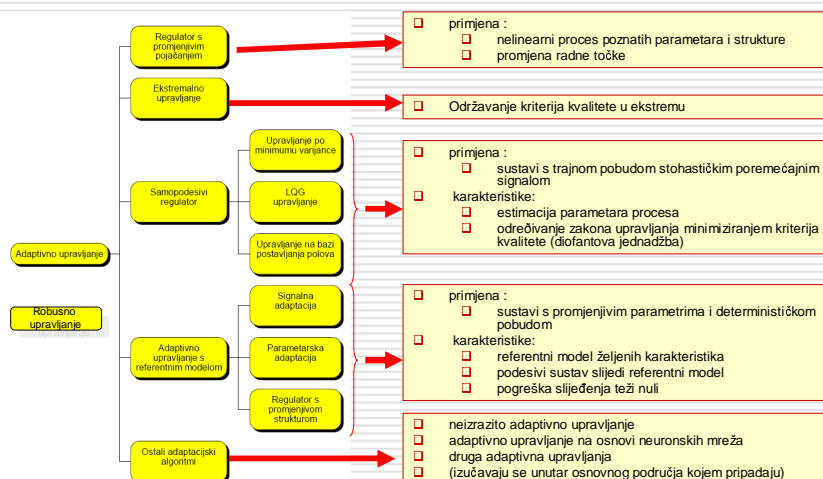
prof. dr. sc. Željko Ban

e-mail: [zeljko.ban@fer.hr](mailto:zeljko.ban@fer.hr)

1



## Podjela adaptivnog upravljanja



Adaptivno i robustno upravljanje


2



## Adaptivno upravljanje na osnovi samopodesivih regulatora



- Svojstva
  - Osigurava traženu kvalitetu regulacije bez obzira na promjene parametara sustava
  - Parametri regulatora se određuju u realnom vremenu iz parametara estimiranog modela procesa
  - Estimirani model procesa LINEARAN
- Koraci tijekom rada u realnom vremenu
  - Estimacija parametara modela
  - Sinteza regulatora
  - Proračun signala izlaza iz regulatora za slijedeći korak diskretizacije
- Vrsta modela
  - Linearni
  - Jedan ulaz jedan izlaz (SISO)
  - S konstantnim parametrima
  - Diskretni




## Vrste modela sustava



Opći oblik diskretnog linearnog SISO modela s konstantnim parametrima

$$A(q) \cdot y(k) = \frac{B(q)}{F(q)} u(k) + \frac{C(q)}{D(q)} e(k)$$



$q^{-1}$  – operator kašnjenja za jedan korak diskretizacije  
 $q^{-1}f(k)=f(k-1)$

y – izlazna varijabla  
u – ulazna varijabla  
e – nezavisna nekorelirana slučajna poremećajna varijabla sa srednjom vrijednosti 0 i standardnom devijacijom  $\sigma$

$$A(q) = 1 + a_1 q^{-1} + a_2 q^{-2} + \dots + a_{na} q^{-na}$$

$$B(q) = 1 + b_1 q^{-1} + b_2 q^{-2} + \dots + b_{nb} q^{-nb}$$

$$C(q) = 1 + c_1 q^{-1} + c_2 q^{-2} + \dots + c_{nc} q^{-nc}$$

$$D(q) = 1 + d_1 q^{-1} + d_2 q^{-2} + \dots + d_{nd} q^{-nd}$$

$$F(q) = 1 + f_1 q^{-1} + f_2 q^{-2} + \dots + f_{nf} q^{-nf}$$



## Vrste modela sustava



Specijalizirani modeli su podskupovi općeg modela

Opći model

$$A(q) \cdot y(k) = \frac{B(q)}{F(q)} u(k) + \frac{C(q)}{D(q)} e(k)$$

### ARMAX


Auto Regresive Moving  
Average eXogenous

$$A(q) \cdot y(k) = q^{-d} \cdot B(q) \cdot u(k) + C(q) \cdot e(k)$$

Ay – Auto regresion

Bu – extra input


Ce – Moving average of the white noise



### ARX

Auto Regresive eXtra input

$$A(q) \cdot y(k) = B(q) \cdot u(k) + e(k)$$



Adaptivno i robusno upravljanje

5



## Vrste modela sustava



Specijalizirani modeli su podskupovi općeg modela


Opći model

$$A(q) \cdot y(k) = \frac{B(q)}{F(q)} u(k) + \frac{C(q)}{D(q)} e(k)$$

### OE

Output error


$$y(k) = \frac{B(q)}{F(q)} u(k) + e(k)$$



### BJ

Box-Jenkins

$$y(k) = \frac{B(q)}{F(q)} u(k) + \frac{C(q)}{D(q)} e(k)$$



Adaptivno i robusno upravljanje

6



## Vrste modela sustava




### Model sustava s mjerljivom smetnjom i driftom

$$A(q) \cdot y(k) = q^{-d} \cdot B(q) \cdot u(k) + H(q) \cdot v(k) + w(k) + C(q) \cdot e(k)$$

$u(k)$  – upravljački ulaz  
 $v(k)$  – mjerljivi poremećaj  
 $w(k)$  – drift  
 $e(k)$  – slučajni poremećaj

$$\begin{aligned} A(q) &= 1 + a_1 q^{-1} + a_2 q^{-2} + \dots + a_{na} q^{-na} \\ B(q) &= b_0 + b_1 q^{-1} + b_2 q^{-2} + \dots + b_{nb} q^{-nb} \\ C(q) &= 1 + c_1 q^{-1} + c_2 q^{-2} + \dots + c_{nc} q^{-nc} \\ H(q) &= h_0 + h_1 q^{-1} + h_2 q^{-2} + \dots + h_{nh} q^{-nh} \end{aligned}$$

$$w(k) = w_0 + w_1 k + w_2 k^2 + \dots + w_{nw} q^{nw}$$



$w(k)$  – drift je modeliran pomoću polinomske funkcije vremena

Većina slučajeva drifta se može prikazati s  $w(k)=w_0$



## Odabir karakteristika modela



- ☐ Odabrani model mora
  - dobro opisivati sustav
  - imati najjednostavniju strukturu koja dobro opisuje sustav
  - biti najnižeg mogućeg reda za dobar opis sustava
- ☐ Za potrebe adaptivnog upravljanja
  - estimacija u realnom vremenu
  - fiksira se struktura modela (kod definiranja algoritma)
  - fiksira se red modela
  - fiksira se korak uzorkovanja
- ☐ Metode identifikacije
  - Metoda najmanjih kvadrata (*Least Squares – LS*)
  - Metoda pomoćnih varijabli (*Instrumental Variable – IV*)
  - Metoda najveće sličnosti (*Maximum – Likelihood – ML*)



## Regresijski oblik modela

pogodan za identifikaciju metodom najmanjih kvadrata



$$A(q) \cdot y(k) = q^{-d} \cdot B(q) \cdot u(k) + H(q) \cdot v(k) + w(k) + C(q) \cdot e(k)$$


$$A(q) = 1 + a_1 q^{-1} + a_2 q^{-2} + \dots + a_{na} q^{-na}$$

$$B(q) = b_0 + b_1 q^{-1} + b_2 q^{-2} + \dots + b_{nb} q^{-nb}$$

$$C(q) = 1 + c_1 q^{-1} + c_2 q^{-2} + \dots + c_{nc} q^{-nc}$$

$$H(q) = h_0 + h_1 q^{-1} + h_2 q^{-2} + \dots + h_{nh} q^{-nh}$$

$$w(k) = w_0 + w_1 k + w_2 k^2 + \dots + w_{nw} q^{nw}$$



$$y_k = \Theta^T \cdot \varphi_k + e_k = \varphi_k^T \Theta + e_k$$

Vektor parametara

$$\Theta^T = \begin{bmatrix} -a_1 & -a_2 & \dots & -a_{na} & b_0 & b_1 & \dots & b_{nb} & h_0 & h_1 & \dots & h_{nh} & w_0 & w_1 & \dots & w_{nw} & c_1 & c_2 & \dots & c_{nc} \end{bmatrix}$$

$$\varphi_k^T = \begin{bmatrix} y_{k-1} & y_{k-2} & \dots & y_{k-na} & u_{k-d} & u_{k-d-1} & \dots & u_{k-d-nb} & v_k & v_{k-1} & \dots & v_{k-nh} \end{bmatrix}$$

$$\begin{bmatrix} 1 & k & \dots & k^{nw} & e_{k-1} & e_{k-2} & \dots & e_{k-nc} \end{bmatrix}$$

Vektor regresije

Adaptivno i robustno upravljanje

9



## Regresijski oblik modela - primjer



$$A(q) = 1 + a_1 q^{-1} + a_2 q^{-2} + \dots + a_{na} q^{-na}$$

$$B(q) = b_0 + b_1 q^{-1} + b_2 q^{-2} + \dots + b_{nb} q^{-nb}$$

$$C(q) = 1 + c_1 q^{-1} + c_2 q^{-2} + \dots + c_{nc} q^{-nc}$$


$$H(q) = h_0 + h_1 q^{-1} + h_2 q^{-2} + \dots + h_{nh} q^{-nh}$$

$$w(k) = w_0 + w_1 k + w_2 k^2 + \dots + w_{nw} q^{nw}$$

Primjer:

k=6

na=3, nb=2, d=1, nh=1, nw=1, nc=1



$$\Theta^T = [-a_1 \quad -a_2 \quad -a_3 \quad b_0 \quad b_1 \quad b_2 \quad h_0 \quad h_1 \quad w_0 \quad w_1 \quad c_1]$$

$$\varphi_k^T(6) = [y_5 \quad y_4 \quad y_3 \quad u_5 \quad u_4 \quad u_3 \quad v_6 \quad v_5 \quad 1 \quad 6 \quad e_5]$$

$$y_6 = \Theta^T \cdot \varphi_6 + e_6 = \varphi_6^T \Theta + e_6$$

Adaptivno i robustno upravljanje

10



## Algoritam najmanjih kvadrata



Početna jednadžba

$$y_k = \Theta^T \cdot \varphi_k + e_k = \varphi_k^T \Theta + e_k$$

Predikcija izlazne varijable uz vektor parametara  $\Theta$  iz prošlog koraka

$$\hat{y}(k | \Theta) = \Theta^T (k-1) \cdot \varphi(k)$$

uz  $e(k)$  nekorelirani bijeli šum očekivanje iznosi

$$E\{e(k)\} = 0$$

Pogreška predikcije

$$\varepsilon(k) = y(k) - \hat{y}(k | \Theta)$$

Uz poznatu strukturu modela i mjerene podatke iz vektora  $\varphi$  izlazna varijabla sustava se opisuje sa

$$y(k) = \varphi^T(k) \hat{\Theta} + \hat{\varepsilon}(k)$$

$\hat{\Theta}$  – estimirani vektor parametara modela

$\hat{\varepsilon}(k)$  – pogreška estimacije u trenutku  $k$

Cilj je odrediti  $\hat{\Theta}$  sa svojstvom da pogreška estimacije  $\hat{\varepsilon}$  bude minimalna

$$\hat{\varepsilon}(k) = e(k) + \varphi^T(k) [\Theta - \hat{\Theta}]$$

Ako se postigne  $\Theta = \hat{\Theta}$  vrijedi:

$$\hat{\varepsilon}(k) \approx e(k) \quad \text{za} \quad \Theta \approx \hat{\Theta}$$

Adaptivno i robusno upravljanje

11



## Algoritam najmanjih kvadrata



Vektor parametara u općem obliku

$$\Theta^T = \begin{bmatrix} \underbrace{-a_1 \ -a_2 \ \dots \ -a_{n_a}}_{n_a} \ \underbrace{b_0 \ b_1 \ \dots \ b_{n_b}}_{n_b+1} \ \underbrace{h_0 \ h_1 \ \dots \ h_{n_h}}_{n_h+1} \ \underbrace{w_0 \ w_1 \ \dots \ w_{n_w}}_{n_w+1} \ \underbrace{c_1 \ c_2 \ \dots \ c_{n_c}}_{n_c} \end{bmatrix}$$

ima  $n_{par}$  parametara:

$$n_{par} = n_a + n_b + 1 + n_h + 1 + n_w + 1 + n_c$$

Za uspješnu estimaciju, sustav mora raditi dovoljno dugo da se formira  $N$  vektora podataka, gdje je:

$$N > n_{par}$$

Vektori imaju oblik

$$\begin{bmatrix} y(1) \\ y(2) \\ \vdots \\ y(N) \end{bmatrix} = \begin{bmatrix} \varphi^T(1) \\ \varphi^T(2) \\ \vdots \\ \varphi^T(N) \end{bmatrix} \hat{\Theta} + \begin{bmatrix} \hat{\varepsilon}(1) \\ \hat{\varepsilon}(2) \\ \vdots \\ \hat{\varepsilon}(N) \end{bmatrix}$$

$$Y = \Phi \hat{\Theta} + \hat{E}$$

gdje su:

$$Y = \begin{bmatrix} y(1) \\ y(2) \\ \vdots \\ y(N) \end{bmatrix}; \quad \Phi = \begin{bmatrix} \varphi^T(1) \\ \varphi^T(2) \\ \vdots \\ \varphi^T(N) \end{bmatrix}; \quad \hat{E} = \begin{bmatrix} \hat{\varepsilon}(1) \\ \hat{\varepsilon}(2) \\ \vdots \\ \hat{\varepsilon}(N) \end{bmatrix}$$

$$\hat{E} = Y - \Phi \hat{\Theta}$$

Adaptivno i robusno upravljanje

12



## Princip najmanjih kvadrata



Suma kvadrata razlike mjenenog vektora  $Y$  i estimiranog izlaznog vektora mora biti minimalna.

$$J(\hat{\theta}) = \frac{1}{2} \sum_{i=1}^N \hat{\varepsilon}_i^2(k) = \frac{1}{2} \hat{E}^T \hat{E} = \frac{1}{2} \|\hat{E}\|^2$$

Otežana suma kvadrata razlike mjenenog vektora  $Y$  i estimiranog izlaznog vektora (težinski faktori – mjera preciznosti)

$$J(\hat{\theta}) = \frac{1}{2} \sum_{i=1}^N q_i \hat{\varepsilon}_i^2(k) = \frac{1}{2} \hat{E}^T Q \hat{E}$$

Kriterij najmanjih kvadrata

$$J(\hat{\theta}) = \frac{1}{2} \hat{E}^T \hat{E} = (Y - \Phi \hat{\theta})^T (Y - \Phi \hat{\theta})$$

$$J(\hat{\theta}) = Y^T Y - Y^T \Phi \hat{\theta} - \hat{\theta}^T \Phi^T Y + \hat{\theta}^T \Phi^T \Phi \hat{\theta}$$

Traženje ekstrema

-derivacija kriterija po parametrima = 0  
-(Jacobian matrica)

$$\frac{\partial J(\hat{\theta})}{\partial \hat{\theta}} = \Phi^T \Phi \hat{\theta} - Y^T \Phi$$

Minimum se postiže uz pozitivnu 2. derivaciju kriterija po parametrima (Hessian)

$$\left[ \frac{\partial^2 J(\hat{\theta})}{\partial^2 \hat{\theta}} \right] = \Phi^T \Phi \geq 0$$



## Princip najmanjih kvadrata



$$J(\hat{\theta}) = \frac{1}{2} \sum_{i=1}^N \hat{\varepsilon}_i^2(k) = \frac{1}{2} \hat{E}^T \hat{E} = \frac{1}{2} \|\hat{E}\|^2$$

Izjednačavanjem gradijenta s nulom dobije se izraz za estimirane parametre:

$$\frac{\partial J(\hat{\theta})}{\partial \hat{\theta}} = \Phi^T \Phi \hat{\theta} - Y^T \Phi = 0$$

$$\hat{\theta}_{LS} = (\Phi^T \Phi)^{-1} \Phi^T Y = \Phi^+ Y$$

gdje je

$\Phi^+$  – pseudoinverz od  $\Phi$

Pseudoinverzna matrica matrice  $\Phi$  postoji ako matrica  $\Phi$  ima puni rang (zadovoljeno uz stalnu pobudu sustava test signalom)

Pogreška estimacije (rezidui – ostaci)

$$\hat{E} = R^T = [\eta(1) \quad \eta(1) \quad \dots \quad \eta(N)]$$

Iz jednadžbe

$$\hat{E} = R^T = Y - \Phi \hat{\theta}_{LS}$$

proizlazi

$$\Phi^T Y = \Phi^T \Phi \hat{\theta}_{LS} + \Phi^T R$$

$$\Phi^T R = 0$$



## Princip najmanjih kvadrata



Iz definicije rezidua

$$R = (y - \Phi \hat{\theta}_{LS})$$

$i$  uvjeta

$$\Phi^T R = 0$$

$$[\varphi(1) \ \varphi(2) \ \dots \ \varphi(N)] R = 0$$

Za velik broj  $N$ , uvjeti poprimaju oblik

$$E\{y(k-i)\eta(k)\} = 0 \quad \forall \ i = 1, 2, \dots, n_a$$

$$E\{u(k-i)\eta(k)\} = 0 \quad \forall \ i = 1, 2, \dots, n_b + 1$$

proizlazi

$$\sum_{k=1}^N y(k-i)\eta(k) = 0 \quad \forall \ i = 1, 2, \dots, n_a$$

$$\sum_{k=1}^N u(k-i)\eta(k) = 0 \quad \forall \ i = 1, 2, \dots, n_b + 1$$



## Svojstva estimatora na osnovi najmanjih kvadrata



### ☐ RLS - Recursive Least Square

### ☐ Svojstva

#### ☒ $\hat{\theta}_{LS}$ je slučajna varijabla

#### ☐ može se analizirati pomoću jednadžbe

$$y(k) = \varphi^T(k)\hat{\theta} + \hat{\varepsilon}(k)$$

#### ☐ karakteriziraju je

##### ☒ bias

- sistemska pogreška estimiranih parametara

##### ☒ kovarijanca

- raspršenje estimiranih parametara uzrokovanih slučajnom pogreškom





## Svojstva RLS estimatora



### □ Bias

- Uzimajući jednadžbu

$$y(k) = \varphi^T(k)\hat{\theta} + \varepsilon(k)$$

- za  $k=1, 2, \dots, N$

- Dobije se

$$Y = \Phi\hat{\theta} + \hat{E}$$

- Uvrštenjem u jednadžbu estimiranih parametara

$$\hat{\theta}_{LS} = (\Phi^T\Phi)^{-1}\Phi^TY$$

- Dobije se

$$\hat{\theta}_{LS} = (\Phi^T\Phi)^{-1}[\Phi^T\Phi\theta + \Phi^T\hat{E}] =$$

$$= \theta(\Phi^T\Phi)^{-1}\Phi^T\hat{E}$$

- Srednja devijacija estimiranih parametara od stvarne vrijednosti određena je sa

$$\hat{\theta}_{LS} - \theta = (\Phi^T\Phi)^{-1}\Phi^T\hat{E}$$

- Uz determinističke podatke u  $\Phi$  i srednju vrijednost  $e(k)$  jednaku 0, očekivanje pogreške parametara ima oblik

$$E\{\hat{\theta}_{LS} - \theta\} = (\Phi^T\Phi)^{-1}\Phi^TE_E\{\hat{E}\} = 0$$

- Uz slučajne ali nezavisne elemente matrice  $\Phi$  dobije se očekivanje

$$E\{\hat{\theta}_{LS} - \theta\} = E_\Phi\{(\Phi^T\Phi)^{-1}\Phi^T\}E_E\{\hat{E}\} = 0$$

- indeks  $\Phi$  i  $E$  označavaju očekivanje s obzirom na  $\Phi$  i  $E$  objekte

### □ Zaključak

- Potrebna asimptotska nekoreliranost šuma  $e$  i podataka  $\Phi$  za estimaciju bez pogreške



## RLS estimator




- Ne osvježavaju se svi podaci u svakom koraku  $k$ 
  - ne računa se cijeli

$$\hat{\theta}_{LS}(k)$$

- dodaje se samo jedan novi podatak i računa se

$$\hat{\theta}_{LS}(k+1)$$

- Rekurzivni proces prikazan slikom





## RLS estimator



Za  $\hat{\theta}_{LS}$  uzimajući podatke od 1 do k estimirani parametri imaju oblik

$$\hat{\theta}_{LS} = (\Phi^T(k)\Phi(k))^{-1} \Phi^T(k)Y(k)$$

$$\hat{\theta}_{LS}(k+1) = (\Phi^T(k+1)\Phi(k+1))^{-1} \Phi^T(k+1)Y(k+1)$$

$\Phi(k)$  je vremenska funkcija i zasnovan je na podacima u vremenskim koracima od 1 do t

$$Y(k) = \begin{bmatrix} y(1) \\ y(2) \\ \vdots \\ y(k) \end{bmatrix}; \quad \Phi(k) = \begin{bmatrix} \varphi^T(1) \\ \varphi^T(2) \\ \vdots \\ \varphi^T(k) \end{bmatrix}$$

$$\Phi^T(k+1)\Phi(k+1) = \begin{bmatrix} \Phi^T(k) & \varphi(k+1) \end{bmatrix} \begin{bmatrix} \Phi(k) \\ \varphi^T(k+1) \end{bmatrix}$$

$$= \Phi^T(k)\Phi(k) + \varphi(k+1)\varphi^T(k+1)$$

U trenutku k+1 određuje se novo mjerenje iz procesa tako da se dobije

$$Y(k+1) = \begin{bmatrix} y(1) \\ y(2) \\ \vdots \\ y(k) \\ y(k+1) \end{bmatrix} = \begin{bmatrix} Y(k) \\ y(k+1) \end{bmatrix}; \quad \Phi(k+1) = \begin{bmatrix} \varphi^T(1) \\ \varphi^T(2) \\ \vdots \\ \varphi^T(k) \\ \varphi^T(k+1) \end{bmatrix} = \begin{bmatrix} \Phi(k) \\ \varphi^T(k+1) \end{bmatrix}$$



## RLS estimator



Estimirani parametri u trenutku k+1 imaju oblik

$$\hat{\theta}_{LS}(k+1) = (\Phi^T(k+1)\Phi(k+1))^{-1} \Phi^T(k+1)Y(k+1)$$

Prema tome je

$$\Phi^T(k+1)\Phi(k+1) = \begin{bmatrix} \Phi^T(k) & \varphi(k+1) \end{bmatrix} \begin{bmatrix} \Phi(k) \\ \varphi^T(k+1) \end{bmatrix}$$

$$= \Phi^T(k)\Phi(k) + \varphi(k+1)\varphi^T(k+1)$$

Na taj način se lako odrede nove vrijednosti za  $\Phi^T(k+1)\Phi(k+1)$  no problem je odrediti njihovu inverznu matricu direktno (rekurzivnom metodom) bez potrebe za treženjem kompletne inverzne matrice u svakom koraku.

Osim toga potrebno je izračunati  $\Phi^T(k+1)Y(k+1)$



## RLS estimator



Uvrštenjem vrijednosti za

$$\Phi^T(k+1) \quad \text{ i } \quad Y(k+1)$$

Dobije se

$$\begin{aligned} \Phi^T(k+1)Y(k+1) &= \begin{bmatrix} \Phi^T(k) & \varphi(k+1) \end{bmatrix} \begin{bmatrix} Y(k) \\ y(k+1) \end{bmatrix} \\ &= \Phi^T(k)Y(k) + \varphi(k+1)y(k+1) \end{aligned}$$

Uvođenjem oznaka

$$P(k) = \left[ \Phi^T(k)\Phi(k) \right]^{-1}$$

$$B(k) = \Phi^T(k)Y(k)$$

Jednadžbe estimiranih parametara u  $k$  i  $k+1$  koraku imaju oblik

$$\hat{\theta}_{LS}(k+1) = P(k+1)B(k+1)$$

$$\hat{\theta}_{LS}(k) = P(k)B(k)$$

Uz

$$\Phi^T(k+1)\Phi(k+1) = \Phi^T(k)\Phi(k) + \varphi(k+1)\varphi^T(k+1)$$

Slijedi

$$P^{-1}(k+1) = P^{-1}(k) + \varphi(k+1)\varphi^T(k+1)$$

Uz

$$\Phi^T(k+1)Y(k+1) = \Phi^T(k)Y(k) + \varphi(k+1)y(k+1)$$

Slijedi

$$B(k+1) = B(k) + \varphi(k+1)y(k+1)$$

Rekurzivno računanje novih vrijednosti



## RLS estimator



Lema inverzije matrica

Neka su:

$$A = P^{-1}(k) \quad B = \varphi(k+1) \quad C = 1 \quad D = \varphi^T(k+1)$$

Matrice kompatibilnih dimenzija tako da postoji produkt i suma oblika

$$A + BCD = P^{-1}(k) + \varphi(k+1)\varphi^T(k+1)$$

Tada vrijedi

$$[A + BCD]^{-1} = A^{-1} - A^{-1}B[C^{-1} + DA^{-1}B]^{-1}DA^{-1}$$

Uzimajući vrijednosti matrica prema polinomima estimacije dobije se

$$\begin{aligned} & \left[ P^{-1}(k) + \varphi(k+1)\varphi^T(k+1) \right]^{-1} \\ &= P(k) - \frac{P(k)\varphi(k+1)\varphi^T(k+1)P(k)}{1 + \varphi^T(k+1)P(k)\varphi(k+1)} \end{aligned}$$

Temeljem ove leme riješen je problem inverzije matrice u svakom koraku (dijeljenje sa skalarom u svakom koraku)



## RLS estimator



Prema lemi inverzije

$$\begin{aligned} & \left[ P^{-1}(k) + \varphi(k+1)\varphi^T(k+1) \right]^{-1} \\ &= P(k) - \frac{P(k)\varphi(k+1)\varphi^T(k+1)P(k)}{1 + \varphi^T(k+1)P(k)\varphi(k+1)} \end{aligned}$$

$P(k)$  je pozitivno definitna matrica  
jednaka kovarijancnoj matrici od  $\Theta(k)$

dobije se

s očekivanjem  $\hat{\Theta}_{LS}(k)$

$$P(k+1) = P(k) - \frac{P(k)\varphi(k+1)\varphi^T(k+1)P(k)}{1 + \varphi^T(k+1)P(k)\varphi(k+1)}$$

Zamjenom  $y(k+1)$  iz jednadžbe  $\varepsilon(k+1) = y(k+1) - \varphi^T(k+1)\hat{\Theta}_{LS}(k)$   
 $= y(k+1) - \hat{y}(k+1)$

U jednadžbu

$$B(k+1) = B(k) + \varphi(k+1)y(k+1)$$

dobije se

$$B(k+1) = B(k) + \varphi(k+1)\varphi^T(k+1)\hat{\Theta}_{LS}(k) + \varphi(k+1)\varepsilon(k+1)$$

Adaptivno i robusno upravljanje

23



## RLS estimator



Iz jednadžbe

$$P^{-1}(k+1)\hat{\Theta}_{LS}(k+1) = \underbrace{\left[ P^{-1}(k) + \varphi(k+1)\varphi^T(k+1) \right]}_{P^{-1}(k+1)} \hat{\Theta}_{LS}(k) + \varphi(k+1)\varepsilon(k+1)$$

množenjem sa  $P(k+1)$  dobije se

$$\hat{\Theta}_{LS}(k+1) = \hat{\Theta}_{LS}(k) + \underbrace{P(k+1)\varphi(k+1)}_{L(k+1)}\varepsilon(k+1)$$

Adaptivno i robusno upravljanje

24



## RLS algoritam



$$\hat{\Theta}_{LS}(k+1) = \hat{\Theta}_{LS}(k) + P(k+1)\varphi(k+1)\varepsilon(k+1)$$

$$\varepsilon(k+1) = y(k+1) - \varphi^T(k+1)\hat{\Theta}_{LS}(k)$$

$$P(k+1) = P(k) - \frac{P(k)\varphi(k+1)\varphi^T(k+1)P(k)}{1 + \varphi^T(k+1)P(k)\varphi(k+1)}$$

Za ARMAX model s  $d=1$  i  $C(q)=1$  regresijski vektor ima oblik

$$\varphi^T(k) = [-y_{k-1} \quad \dots \quad -y_{k-na} \quad u_{k-1} \quad \dots \quad u_{k-nb-1}]$$

Vektor estimiranih parametara

$$\hat{\Theta}_{LS} = [\hat{a}_1 \quad \hat{a}_2 \quad \dots \quad \hat{a}_{na} \quad \hat{b}_0 \quad \hat{b}_1 \quad \dots \quad \hat{b}_{nb}]$$



## Pseudokod RLS algoritma



Inicijaliziraj algoritam sa  $P(0)$ ,  $\hat{\Theta}(0)$

Formiraj  $\varphi(k+1)$  iz novih mjerenih podataka

Formiraj  $\varepsilon(k+1)$  iz novih mjerenih podataka

$$\varepsilon(k+1) = y(k+1) - \varphi^T(k+1)\hat{\Theta}(k)$$

Izračunaj  $P(k+1)$

$$P(k+1) = P(k) - \frac{P(k)\varphi(k+1)\varphi^T(k+1)P(k)}{1 + \varphi^T(k+1)P(k)\varphi(k+1)}$$

Izračunaj  $\hat{\Theta}(k+1)$

$$\hat{\Theta}(k+1) = \hat{\Theta}(k) + P(k+1)\varphi(k+1)\varepsilon(k+1)$$

Čekaj slijedeći korak diskretizacije



## Svojstva RLS algoritma



- ❑ RLS algoritam estimira samo koeficiente polinoma A i B
- ❑ RLS ne daje dobre rezultate uz obojeni šum
- ❑ Ukoliko se kao pogreška uzme  $C(q)e(k)$ 
  - dobiva se pogreška (bias) kod estimacije polinoma A i B



## Inicijalizacija estimatora



- ❑ Inicijalizacija početnih parametara estimatora
  - Vektor regresije  $\varphi(0)$
  - Početni vektor parametara  $\hat{\theta}_{LS}(0)$
  - Početna matrica kovarijance  $P(0)$



## Inicijalizacija vektora regresije $\varphi(0)$



- Sakupljanje podataka prije pokretanja algoritma rekursivne estimacije

- broj potrebnih koraka za skupljanje podataka

- ovisi o modelu

$$A(q) \cdot y(k) = q^{-d} \cdot B(q) \cdot u(k) + H(q) \cdot v(k) + w(k) + C(q) \cdot e(k)$$


$$A(q) = 1 + a_1 q^{-1} + a_2 q^{-2} + \dots + a_{na} q^{-na}$$

$$B(q) = b_0 + b_1 q^{-1} + b_2 q^{-2} + \dots + b_{nb} q^{-nb}$$

$$C(q) = 1 + c_1 q^{-1} + c_2 q^{-2} + \dots + c_{nc} q^{-nc}$$

$$H(q) = h_0 + h_1 q^{-1} + h_2 q^{-2} + \dots + h_{nh} q^{-nh}$$

$$w(k) = w_0 + w_1 k + w_2 k^2 + \dots + w_{nw} q^{nw}$$



$$\kappa = \max \{ na, \quad nb + 1, \quad nh + 1, \quad nw + 1, \quad nc \}$$



## Inicijalizacija vektora regresije $\varphi(0)$ *Primjer*



### Primjer

Proces opisan sa:

$$y(k) = \varphi^T(k) \hat{\Theta}$$

gdje su:

$$\hat{\Theta}^T = [\hat{a}_1 \quad \hat{b}_0 \quad \hat{b}_1 \quad \hat{b}_2]$$

$$\varphi^T(k) = [-y(k-1) \quad u(k-1) \quad u(k-2) \quad u(k-3)]$$

- vektor regresije treba
  - 3 koraka da sakupi dovoljno prošlih vrijednosti  $u(k)$
- u četvrtom koraku
  - startanje rekursivnog estimatora



## Inicijalizacija vektora parametara



$$\hat{\theta}_{LS}(0)$$

- ☐ Početna vrijednost vektora parametara
  - nije ključna za konvergenciju postupka estimacije
  - prednost
    - ☐ djelomično poznavanje parametara procesa
  - nepoznati parametri
- ☐ Pretpostavka
  - Sustav je jedan integrator s jediničnim pojačanjem  $G(z) = \frac{h}{z-1}$

$$\begin{bmatrix} \text{Parametri} \\ a_i \quad b_i \end{bmatrix} = \begin{cases} a_1 = 1 \\ a_i = 0 \quad \forall \quad i \neq 1 \\ b_0 = h \\ b_i = 0 \quad \forall \quad i \neq 0 \end{cases}$$



## Inicijalizacija matrice kovarijance



$$P(0)$$

- ☐ Početna vrijednost  $P(0)$  ovisi o
  - nesigurnosti nepoznatih parametara
    - ☐ parametri polinoma A,B,C mogu imati različite početne nesigurnosti
- ☐ Standardni odabir
  - $P(0) = r I_{n_{par}}$ 
    - ☐  $r$  – skalar
    - ☐  $I_{n_{par}}$  – jedinična matrica dimenzije  $n_{par}$
    - ☐  $n_{par}$  – broj parametara za estimaciju
- ☐ Odabir  $r$ :
$$r = \begin{cases} \text{velik} & 100 < r < 1000 \\ \text{mali} & 1 < r < 10 \end{cases}$$
- ☐ Svojstva odabira
  - velik
    - ☐ brži odziv algoritma estimacije
    - ☐ veće fluktuacije parametara (i upravljačkog signala)
  - mali
    - ☐ spor odziv algoritma
    - ☐ sporije promjene parametara
    - ☐ glađi upravljački signal





## Inicijalizacija matrice kovarijance $P(0)$ *Primjer*



### Primjer

Proces opisan sa:

$$y(k) = \varphi^T(k) \hat{\Theta}$$

gdje su:

$$\hat{\Theta}^T = [\hat{a}_1 \quad \hat{a}_2 \quad \hat{b}_0 \quad \hat{b}_1]$$

Pretpostavka boljeg poznavanja koeficijenata  $a_1$  i  $a_2$  i slabijeg poznavanja koeficijenata  $b_0$  i  $b_1$

$$P(0) = \begin{bmatrix} r_{a1} & 0 & 0 & 0 \\ 0 & r_{a2} & 0 & 0 \\ 0 & 0 & r_{b0} & 0 \\ 0 & 0 & 0 & r_{b1} \end{bmatrix} \quad \begin{matrix} r_{a1} = r_{a2} \approx 100 \\ r_{b0} = r_{b1} \approx 1 \end{matrix}$$

Matrica kovarijance u trenutku  $k$

$$P(k) = \left[ P^{-1}(0) + \sum_{i=1}^k \varphi(i) \varphi^T(i) \right]^{-1}$$

### □ Velik $P(0)$

- manji utjecaj od regresijskog vektora
- (zbog recipročne vrijednosti  $P(0)$ )

### □ Mali $P(0)$

- velik utjecaj na  $P(k)$

### □ Početno ponašanje rekursivnog estimatora ovisi o

- Odabiru  $\varphi(0), \hat{\Theta}_{LS}(0)$  i  $P(0)$
- tipu sustava
- obliku pobudnog signala



## Primjer identifikacije



Proces je opisan jednačbom

$$y(k) + ay(k-1) = bu(k-1) + e(k) + ce(k-1)$$

s parametrima

$$a = -0.8 ; b(k) = 0.5 \quad \forall k > 0 ; c = 0$$

$e(k)$  je bijeli šum sa  $E\{e(k)\}=0$  i  $E\{e^2(k)\}=0.25$

Inicijalizacija parametara estimatora

$$P(0) = \begin{bmatrix} 100 & 0 \\ 0 & 100 \end{bmatrix} ; \hat{\Theta}(0) = \begin{bmatrix} \hat{a}(0) \\ \hat{b}(0) \end{bmatrix} = \begin{bmatrix} 0.0 \\ 0.0 \end{bmatrix}$$

$$\varphi(k-1) = \begin{bmatrix} -y(k-1) & u(k-1) \end{bmatrix} = \begin{bmatrix} 0 & 0 \end{bmatrix} \quad \text{za } k=0$$

Pobudni signal

pravokutni signal perioda 100s  
jedinичne amplitude



## Primjer identifikacije





$$y(k) + ay(k-1) = bu(k-1) + e(k) + ce(k-1)$$

$$a = -0.8 ; b(k) = 0.5 \quad \forall k > 0 ; c = 0$$

$e(k)$  je bijeli šum sa  $E\{e(k)\}=0$  i  $E\{e^2(k)\}=0.25$

$$P(0) = \begin{bmatrix} 100 & 0 \\ 0 & 100 \end{bmatrix} ; \hat{\Theta}(0) = \begin{bmatrix} \hat{a}(0) \\ \hat{b}(0) \end{bmatrix} = \begin{bmatrix} 0.0 \\ 0.0 \end{bmatrix}$$

$$\varphi(k-1) = \begin{bmatrix} -y(k-1) & u(k-1) \end{bmatrix} = \begin{bmatrix} 0 & 0 \end{bmatrix}$$



Adaptivno i robustno upravljanje

35



## Primjer identifikacije proces s promjenjivim parametrima



Proces je opisan jednačbom

$$y(k) + ay(k-1) = bu(k-1) + e(k) + ce(k-1)$$

s parametrima

$$a = -0.8 ;$$

$$\forall k > 0 ; c = 0$$



$$b(k) = \begin{cases} 0.5 & \text{for } 0 < k < 400 \\ 1 & \text{for } 400 \leq k < \infty \end{cases}$$

$e(k)$  je bijeli šum sa  $E\{e(k)\}=0$  i  $E\{e^2(k)\}=0.25$

Inicijalizacija parametara estimatora

$$P(0) = \begin{bmatrix} 100 & 0 \\ 0 & 100 \end{bmatrix} ; \hat{\Theta}(0) = \begin{bmatrix} \hat{a}(0) \\ \hat{b}(0) \end{bmatrix} = \begin{bmatrix} 0.0 \\ 0.0 \end{bmatrix}$$

$$\varphi(k-1) = \begin{bmatrix} -y(k-1) & u(k-1) \end{bmatrix} = \begin{bmatrix} 0 & 0 \end{bmatrix} \quad \text{za } k=0$$




Adaptivno i robustno upravljanje

36



## Primjer identifikacije proces s promjenjivim parametrima




### □ Razlog loše estimacije

- tijekom estimacije trag matrice kovarijance teži nuli

$$\lim_{k \rightarrow \infty} \text{tr}[P(k)] \rightarrow 0$$

- nakon toga algoritam ne reagira na promjenu parametara sustava



Nova vrijednost parametara je zasnovana na staroj

$$\hat{\theta}_{LS}(k+1) = \hat{\theta}_{LS}(k) + P(k+1)\varphi(k+1)\varepsilon(k+1)$$

Novo mjerenje nije uzeto u obzir  
*Algoritam se "ugasio"*

Adaptivno i robustno upravljanje

37



## Algoritam za sustave s promjenjivim parametrima



### □ Poboljšanje algoritma upotrebom

- Eksponencijalnog otežavanja podataka
- Automatska promjena eksponencijalnog faktora zaboravljanja
- Resetiranje matrice kovarijance
- Modificiranje matrice kovarijance

Adaptivno i robustno upravljanje

38



## Eksponencijalno otežavanje podataka



- Kriterij za izvod algoritma prelazi iz

$$J(\hat{\theta}) = \frac{1}{2} \sum_{i=1}^N q_i \hat{e}_i^2(k) = \frac{1}{2} \hat{E}^T Q \hat{E}$$

- u algoritam

$$J(\hat{\theta}) = \frac{1}{2} \sum_{i=1}^N \lambda^{k-1} q_i \hat{e}_i^2(k)$$

- Odabir  $\lambda$  određen

- brzom adaptacijom
- dobom estimacijom
  - za  $\lambda \approx 1$ 
    - greška predikcije starija od  $T_m$  iznosi
    - $e^{-1} \approx 36\%$  prema novijim podacima
    - $T_m = 1/(1-\lambda)$

Algoritam matrice kovarijance

$$P(k+1) = \left[ I - \frac{P(k)\varphi(k+1)\varphi^T(k+1)}{\lambda(k+1) + \varphi^T(k+1)P(k)\varphi(k+1)} \right] P(k)$$

$\lambda(k)$  – eksponencijalni faktor zaboravljanja  
 $0 < \lambda < 1$

Prema iskustvu najbolje je uzeti  
 $0.95 < \lambda < 0.99$

Preporučeni izbor:  $\lambda = 0.98$

Adaptivno i robustno upravljanje

39



## Primjer identifikacije procesa s promjenjivim parametrima



Za proces opisan jednačbom

$$y(k) + ay(k-1) = bu(k-1) + e(k) + ce(k-1)$$

$$a = -0.8; \quad \forall k > 0; \quad c = 0$$



$e(k)$  je bijeli šum sa  $E\{e(k)\} = 0$  i  $E\{e^2(k)\} = 0.25$

Inicijalizacija parametara estimatora

$$b(k) = \begin{cases} 0.5 & \text{for } 0 < k < 400 \\ 1 & \text{for } 400 \leq k < \infty \end{cases}$$

$$P(0) = \begin{bmatrix} 100 & 0 \\ 0 & 100 \end{bmatrix}; \quad \hat{\theta}(0) = \begin{bmatrix} \hat{a}(0) \\ \hat{b}(0) \end{bmatrix} = \begin{bmatrix} 0.0 \\ 0.0 \end{bmatrix}$$

$$\varphi(k-1) = \begin{bmatrix} -y(k-1) & u(k-1) \end{bmatrix} = \begin{bmatrix} 0 & 0 \end{bmatrix} \quad \text{za } k=0$$







## Primjer identifikacije proces s promjenjivim parametrima



### Trag kovarijancne matrice

Nova vrijednost parametara je zasnovana na staroj

$$\hat{\theta}_{LS}(k+1) = \hat{\theta}_{LS}(k) + P(k+1)\varphi(k+1)\varepsilon(k+1)$$



Adaptivno i robustno upravljanje

41



## Vremenski promjenjivi eksponencijalni faktor zaboravljanja



### Vremenska promjena parametra $\lambda$

$$\lambda(k) = \lambda_0 \lambda(k-1) + (1 - \lambda_0)$$

uz

$$\lambda_0 = 0.99$$

$$\lambda(0) = 0.95$$

### u algoritam

$$P(k+1) = \left[ 1 - \frac{P(k)\varphi(k+1)\varphi^T(k+1)}{\lambda(k+1) + \varphi^T(k+1)P(k)\varphi(k+1)} \right] P(k)$$

### Svojstva

- $\lambda$  se mijenja od 0.95 do 0.99
- veća brzina algoritma estimacije u početku

### Optimalni izbor faktora zaboravljanja uzima u obzir

- brzo praćenje promjene parametara
  - veća osjetljivost na šum
- što manje oscilacija estimiranih parametara
  - veća inercija estimatora

### Preporuka odabira

- brze promjene parametara procesa
  - brzo zaboravljanje mjerenih signala
- spore promjene parametara ili ako nema perzistentne pobude
  - sporo zaboravljanje

Adaptivno i robustno upravljanje

42



## Resetiranje matrice kovarijance

- ❑ Resetiranje matrice kovarijance  $P(k)$ 
  - osiguranje da trag matrice ne postane premali
  - svakih  $k_i$  koraka matrica se resetira na vrijednost koja sprečava gašenje algoritma
- ❑ Prim.: nakon  $k_i$  koraka:
$$P(k_i) = \beta_i I_{n_{par}} \quad r = \begin{cases} \text{velik} & 100 < r < 1000 \\ \text{mali} & 1 < r < 10 \end{cases}$$
  - $\beta_i$  – skalar  $\beta_i < r$
- ❑ Nepogodnost
  - izgubljena eksponencijalna konvergencija
  - aktuator stalno aktivan




## Svojstva RLS algoritma

- ❑ Matrica  $P(k)$  mora biti pozitivno definitna
  - računa se oduzimanjem dviju pozitivno definitnih matrica
$$P(k+1) = \left[ I - \frac{P(k)\varphi(k+1)\varphi^T(k+1)}{\lambda(k+1) + \varphi^T(k+1)P(k)\varphi(k+1)} \right] P(k)$$
- Numerička greška računanja
  - ❑  $P(k)$  može prestati biti pozitivno definitna
    - divergencija algoritma estimacije
- U adaptivnom upravljanju
  - ❑ mora se definirati rezervni plan spašavanja sustava u slučaju divergencije algoritma estimacije.



## Svojstva RLS algoritma



- RLS algoritam
  - brza konvergencija
  - pouzdan
  - jednostavan za implementaciju
- Opasnost
  - divergencija algoritma zbog negativno definitne  $P(k)$  zbog akumulacije numeričke pogreške računanja



## Uzrok divergencije



- Konstantan faktor zaboravljanja  $\lambda < 1$
- Nestabilan numerički algoritam za računanje matrice kovarijance  $P(k)$
- Upotreba neperzistentnog pobudnog signala
- Nemjerljivi poremećaji u sustavu
  - opasnost kad referentni signal nije perzistentno pobuđen
- Nemodelirana dinamika procesa